Министерство науки и высшего образования Российской Федерации
Федеральное государственное бюджетное образовательное учреждение высшего образования
«Московский государственный технический университет имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ «Информатика и системы управления»

КАФЕДРА «Программное обеспечение ЭВМ и информационные технологии»

Лабораторная работа №7

По предмету: «Анализ алгоритмов»

Поиск подстроки в строке

Студент: Гасанзаде М.А.,
Группа: ИУ7-56Б

Москва, 2019 г.

Оглавление

Введение

Одна из простейших задач поиска информации. Применяется в виде встроенной функции в текстовых редакторах, СУБД, поисковых машинах, языках программирования и т.п.

Цель работы: изучение алгоритмов поиска подстроки в строке.

Задачи работы:

1) изучение алгоритмов Бойера-Мура и Кнута-Морриса-Пратти

2) реализация этих алгоритмов

3) провести анализ и тестирование

1. Аналитическая часть

В данной части дано теоретическое описание алгоритмов и указание области их применения.

1.1. Описание алгоритмов

Поиск подстроки в строке — одна из простейших задач поиска информации. Применяется в виде встроенной функции в текстовых редакторах, СУБД, поисковых машинах, языках программирования, программы определения плагиата осуществляют онлайн-проверку, используя алгоритмы поиска подстроки среди большого количества документов, хранящихся в собственной базе.

На сегодняшний день существует огромное разнообразие алгоритмов поиска подстроки. Программисту приходится выбирать подходящий в зависимости от таких факторов: длина строки, в которой происходит поиск, необходимость оптимизации, размер алфавита, возможность проиндексировать текст, требуется ли одновременный поиск нескольких строк. В данной лабораторной работе будут рассмотремы два алгоритма сравнения с образцом, алгоритм Кнута-Морриса-Пратта и алгоритм Бойера-Мура.

1.1.1 Стандартный алгоритм

Стандартный алгоритм начинает со сравнения первого символа текста с первым символом подстроки. Если они совпадают, то происходит переход ко второму символу текста и подстроки. При совпадении сравниваются следующие символы. Так продолжается до тех пор, пока не окажется, что подстрока целиком совпала с отрезком текста, или пока не встретятся несовпадающие символы. В первом случае задача решена, во втором мы сдвигаем указатель текущего положения в тексте на один символ и заново начинаем сравнение с подстрокой

1.1.2 Алгоритм Бойера-Мура

Алгоритм Бойера-Мура осуществляет сравнение с образцом справа налево, а не слева направо. Исследуя искомый образец, можно осуществлять более эффективные прыжки в тексте при обнаружении несовпадения. В этом алгоритме кроме таблицы суффиксов применяется таблица стоп-символов. Она заполняется для каждого символа в алфавите. Для каждого встречающегося в подстроке символа таблица заполняется по принципу максимальной позиции символа в строке, за исключением последнего символа. При определении сдвига при очередном несовпадении строк, выбирается максимальное значение из таблицы суффиксов и стоп-символов

1.1.3 Алгоритм Кнута-Морриса-Пратта

Алгоритм Кнута-Морриса-Пратта основан на принципе конечного автомата, однако он использует более простой метод обработки неподходящих символов. В этом алгоритме состояния помечаются символами, совпадение с которыми должно в данный момент произойти. Из каждого состояния имеется два перехода: один соответствует успешному сравнению, другой - несовпадению. Успешное сравнение переводит нас в следующий узел автомата, а в случае несовпадения мы попадаем в предыдущий узел, отвечающий образцу. В программной реализации этого алгоритма применяется массив сдвигов, который создается для каждой подстроки, которая ищется в тексте. Для каждого символа из подстроки рассчитывается значение, равное максимальной длине совпадающего префикса и суффикса относительно конкретного элемента подстроки. Создание этого массива позволяет при несовпадении строки сдвигать ее на расстояние, большее, чем 1 (в отличие от стандартного алгоритма).

1.2. Применение алгоритмов

Алгоритмы применяются в:

1. Системах проверки плагиата;
2. СУБД для поиска данных;
3. Текстовых редакторах

2. Конструкторская часть

В данной части приведены схемы алгоритмов, а также их сравнительный анализ.

2.1 Требования к программе

Требования к вводу: Длина подстроки должна быть меньше чем длина строки.

2.2 Пример работы алгоритмов

В рис. 1 и 2 будет рассмотрена работа алгоритмов КМП и Боейра-Мура на значениях строки text и подстроки pattern

text[]=”AABAACAADAABAABA” pattern[]=”AABA”

Работа алгоритма при КМП:

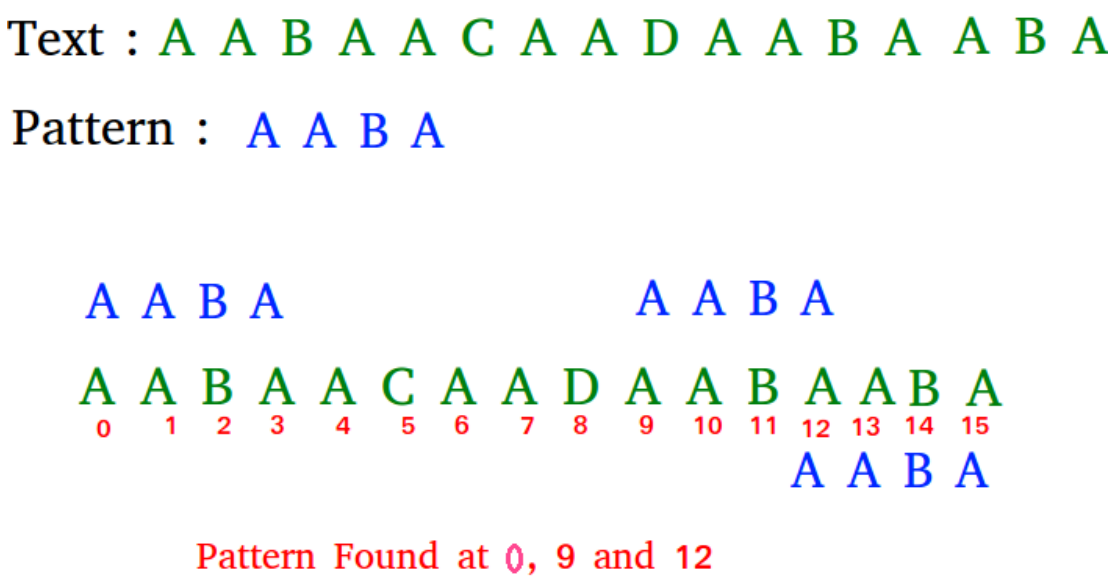

Рисунок 1 – Работа алгоритма КМП

Работа алгоритма БМ при плохом суффиксе:

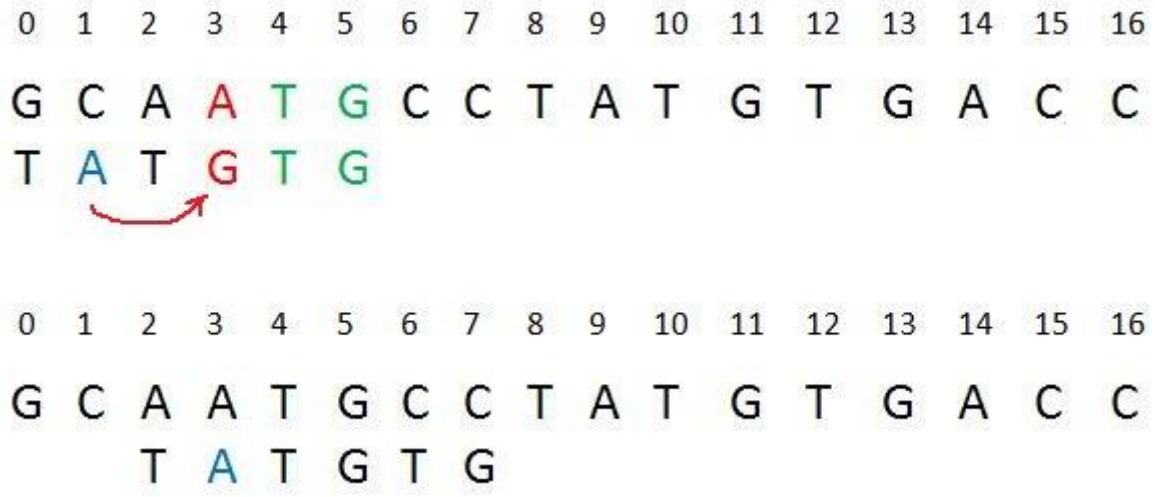

Рисунок 2 - в примере мы получили несоответствие в позиции 3. Здесь наш несовпадающий символ - «A». Теперь мы будем искать последнее вхождение «A» в паттерне. Мы получили «A» в позиции 1 в шаблоне (отображается синим цветом), и это последний случай его появления. Теперь мы сместим шаблон 2 раза, чтобы «A» в шаблоне выровнялось с «A» в тексте.

2.3 Вывод

В данном разделе были рассмотрены основные требования к программе, показана работа алгоритмов на конкретной строке и подстроке.

3. Технологическая часть

В данной части приведены используемые технические средства, а также примеры тестирования и листинг программы.

3.1 Требования к программному обеспечению

Программа должна корректно находить подстроку, верно показывать на её расположение. Требуется также обеспечить возможность замера времени работы каждого алгоритма на различных размерах строки.

3.2 Средства реализации

Выбран язык программирования Python3 за кроссплатформенность, автоматическое освобождение памяти, высокую скорость разработки. Замер процессорного времени проводился функцией perf_counter() модуля time. Функция представлена на *листинге 1*.

Листинг 1 – Текст на котором проводилось тестирование.

```
txt = '''
from math import sin
sin(m)+
sin
asin(db)+
acos(rnrf)+
tan()+
prosto stroka tang()
just string but in english sqrt(1)+
sadece bir xett cos()+
cos
sqrt()+
sqrt
abs!
abs()+
abs)
abs[()] '''
```

3.3 Листинг кода

Исходный код программы приведен на *листингах 2,3,4*.

***Листинг 2* - Стандартный алгоритм поиска**

```
#Naive Pattern Searching algorithm
def search(pat, txt):
    M = len(pat)
    N = len(txt)

    for i in range (N-M+1 ):
        j = 0

        while (j < M):
            if (txt[i+j] != pat[j]):
                break
            j+=1

        if (j == M):
            print ( "Pattern found at index " , i)
    print("End of search")
```

Листинг 3 – Алгоритм Боера-Мура Методом плохого суффикса

```
NO_OF_CHARS = 256

def badCharHeuristic(string, size):
    badChar = [-1]*NO_OF_CHARS
    for i in range(size):
        badChar[ord(string[i])] = i;
    return badChar

def search(txt, pat):
    '''
    A pattern searching function that uses Bad Character
    Heuristic of Boyer Moore Algorithm
    '''
    m = len(pat)
    n = len(txt)
    badChar = badCharHeuristic(pat, m)
    s = 0
    while(s <= n-m):
        j = m-1

        while j>=0 and pat[j] == txt[s+j]:
            j -= 1
        if j<0:
            print("Pattern occur at shift = {}".format(s))
            s += (m-badChar[ord(txt[s+m])] if s+m<n else 1)
        else:
            s += max(1, j-badChar[ord(txt[s+j])])
    print("End of search")
```

Листинг 4 - **Алгоритм КМП**

```
def KMPSearch(pat, txt):
    M = len(pat)
    N = len(txt)

    lps = [0]*M
    j = 0 # index for pat[]
    computeLPSArray(pat, M, lps)
    i = 0 # index for txt[]
    while i < N:
        if pat[j] == txt[i]:
            i += 1
            j += 1

        if j == M:
            print("Found pattern at index " + str(i-j) )
            j = lps[j-1]

        elif i < N and pat[j] != txt[i]:
            if j != 0:
                j = lps[j-1]
            else:
                i += 1

    print("End of search")

def computeLPSArray(pat, M, lps):
    len = 0
    lps[0]
    i = 1

    while i < M:
        if pat[i]== pat[len]:
            len += 1
            lps[i] = len
            i += 1
        else:
            if len != 0:
                len = lps[len-1]
            else:
                lps[i] = 0
                i += 1
```

3.4 Описание тестирования

Тестирование проводится по методу чёрного ящика [2]. Требуется проверить корректность работы.

3.5 Вывод

Текущая реализация на языке Python позволяет корректно находить заданную подстроку, а также производить замеры времени.

4. Экспериментальная часть

В этой части приведены пример интерфейса, входные данные тестирования, результаты замера времени и их анализ.

4.1. Примеры работы

На *рис.* 3, 4, 5 приведены изображения внешнего вида интерфейса программы во время его работы.

```
Word please: sin
Pattern found at index  22
Pattern found at index  30
Pattern found at index  42
Pattern found at index  51
End of search
Elapsed time: 0.0445879
```

Рисунок 3 – Пример стандартной реализации

```
Which word you wanna: sin
Pattern occur at shift = 22
Pattern occur at shift = 30
Pattern occur at shift = 42
Pattern occur at shift = 51
End of search
Elapsed time: 0.0273167
```

Рисунок 4 – Пример работы реализации Байера-Мура

```
Just kill me please: sin
Found pattern at index 18
Found pattern at index 22
Found pattern at index 30
Found pattern at index 35
End of search
Elapsed time: 0.025786999999999997
```

Рисунок 5 – Пример работы реализации КПМ

4.2. Результаты тестирования

В *таблице 1* представлены результаты тестирования по методу чёрного ящика [2] в следующем порядке: стандартный алгоритм, алгоритм Винограда, алгоритм Винограда с набором оптимизаций.

Таблица 3

Результаты тестирования по методу черного ящика

Стандартная реализация	Боейра-Мура	КПМ	Результат
sin	sin	sin	Ответ верный
cos	cos	cos	Ответ верный
sin(	sin(	sin(	Ответ верный
tan(	tan(	tan(	Ответ верный
sqrt(	sqrt(	sqrt(	Ответ верный

Все тесты пройдены успешно.

4.3. Постановка эксперимента по замеру времени

Замер времени проводился для заданного текста. Один эксперимент повторялся не менее 5 раз, результат одного эксперимента рассчитывался как среднее значение результатов проведенных испытаний с одинаковыми входными данными.

4.4. Сравнительный анализ на материале экспериментальных данных

Зависимость времени нахождения подстроки в строке в зависимости от расположения представлен на *рисунках 6,7.*\

Рисунок 6 – Время работы при ложных значениях.

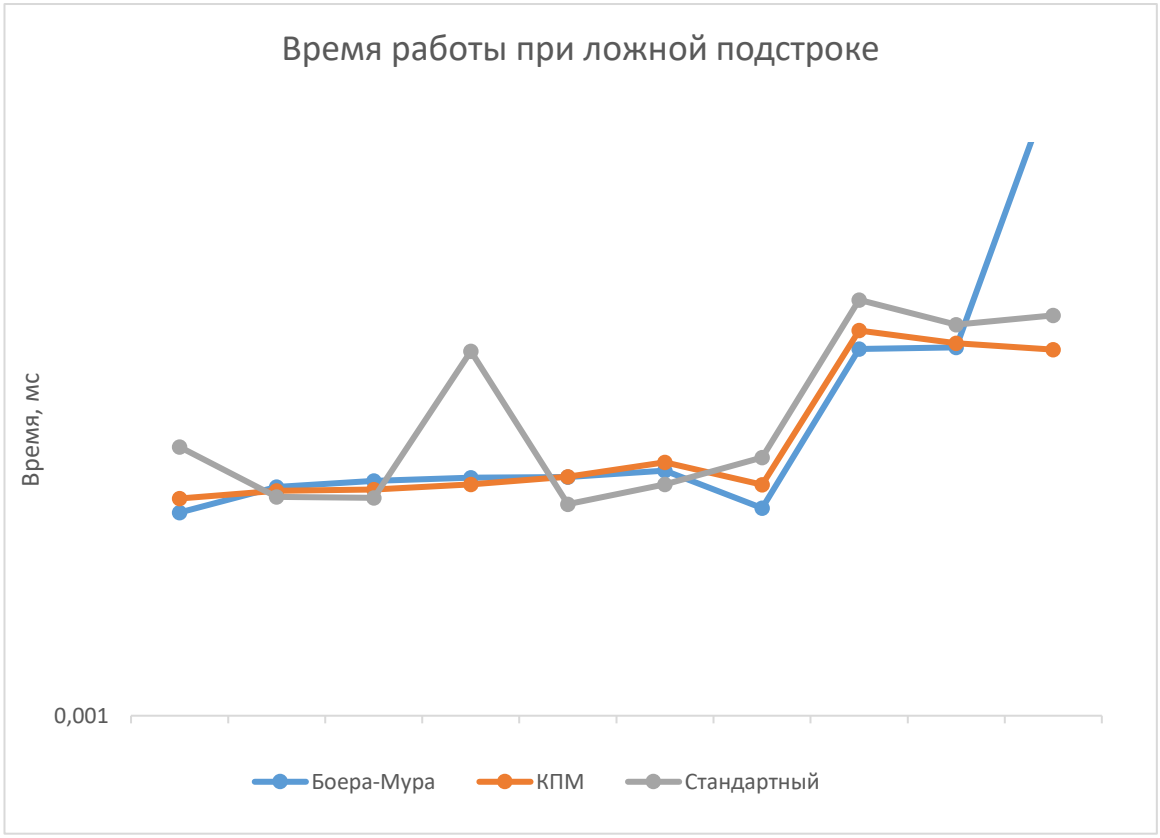

Рисунок 7 – Время работы при поиске слова длиной 4 находящимся в тексте

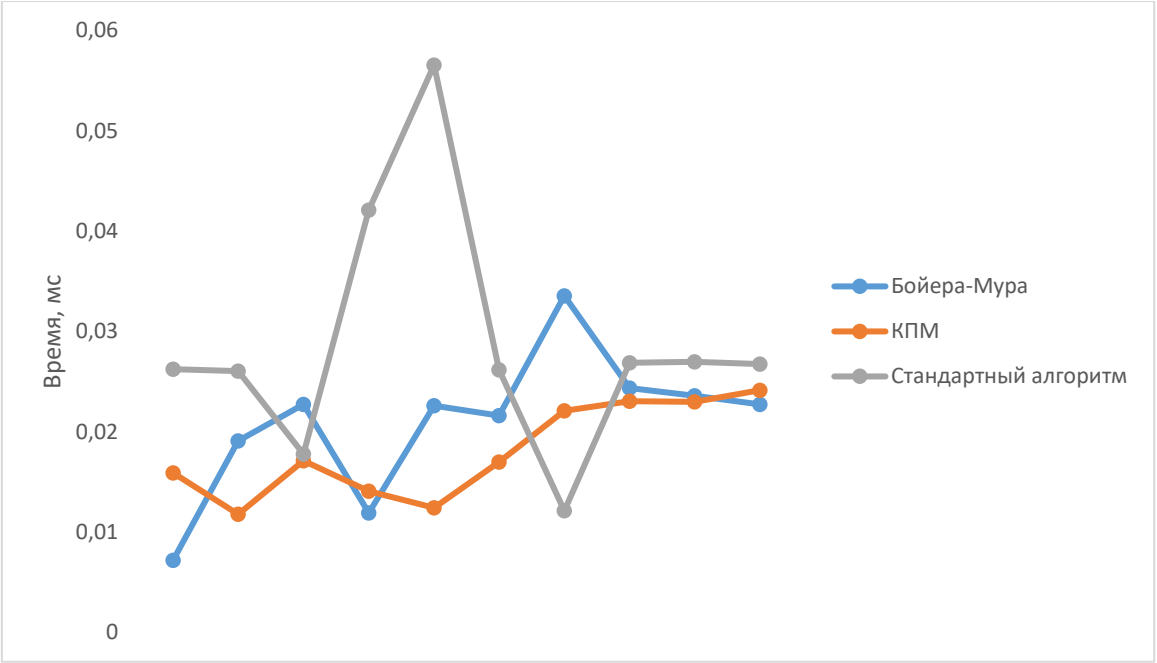

4.5 Вывод

Сравнительный анализ по времени показал, что стандартная реализация алгоритма очень нестабильна, а Бойера-Мура и КПМ показывают одинаковый результат.

Заключение

В ходе лабораторной работы мы изучили возможности применения и реализовали алгоритмы поиска подстроки в строке.

Было проведено тестирование, показавшее, что алгоритмы реализованы правильно.

Временной анализ показал, что-то стандартный метод очень нестабилен и плохо работает при больших запросах.

Список литературы

1. time — Time access and conversions // Python URL: https://docs.python.org/3/library/time.html (дата обращения: 1.11.2019).
2. Kara kutu test technologisi URL:https://www.mobilhanem.com/kara-kutu-test-teknigi-ve-uygulanmasi/ (дата обращения 1.11.2019)
3. Bilgisayar tabanli sistemlerde test otomatizasyonunun tasarlanmasi ve gerçeklenmesi. Hacettepe Üniversitesi: 2015. 70 c. URL:shorturl.wizarmh/2lab
4. Дж. Макконелл. Анализ алгоритмов. Активный обучающий подход.